Projet matière AI pour la BI

Cahier des charges : Data Preparation, Feature Engineering & Machine Learning

1. Contexte général

Dans un contexte industriel, les données disponibles pour l'analyse ne se présentent généralement pas sous la forme d'un fichier unique, propre et directement exploitable par un algorithme de Machine Learning. Les systèmes d'information, notamment les ERP, stockent les informations dans plusieurs tables correspondant à différents processus métier : équipements, interventions, réparations, maintenance préventive, mouvements, catégories, sites, etc.

Le jeu de données fourni dans le cadre de ce projet provient d'un ERP réel de gestion de maintenance industrielle. Il est constitué de plusieurs fichiers CSV liés entre eux.

L'objectif du projet est de vous confronter à une situation proche d'un véritable projet Data: vous devrez partir de données brutes provenant d'un système opérationnel, les comprendre, les préparer, construire une représentation analytique pertinente puis les exploiter dans des approches de Machine Learning supervisé et non supervisé.

Le projet ne consiste donc pas uniquement à entraîner un modèle. Une part importante du travail porte sur la compréhension des données, leur préparation, le Feature Engineering et l'analyse critique des résultats.

2. Objectifs du projet

À l'issue du projet, vous devrez être capables de :

- Comprendre la structure générale d'un dataset relationnel provenant d'un erp ;
- Identifier les tables, les variables et les relations pertinentes pour une problématique donnée ;
- Explorer et évaluer la qualité des données disponibles ;
- Préparer et nettoyer des données réelles ;
- Réaliser des jointures entre plusieurs sources en contrôlant leurs effets ;
- Transformer des données opérationnelles en un dataset analytique exploitable ;
- Construire des variables pertinentes par feature engineering ;
- Identifier les variables inutiles, redondantes ou potentiellement dangereuses ;
- Détecter et prévenir le data leakage, notamment dans les problèmes temporels ;
- Développer et évaluer une approche de machine learning supervisé ;
- Développer et analyser une approche de machine learning non supervisé ;
- Interpréter les résultats obtenus et identifier les limites de la solution proposée ;
- Présenter et défendre techniquement une démarche Data complète.

L'objectif principal n'est pas d'obtenir la meilleure performance possible, mais de construire une démarche méthodologiquement correcte, reproductible et argumentée.

3. Présentation des données

Le projet utilise exclusivement le **dataset ERP Maintenance fourni avec le sujet**.Les données sont réparties dans plusieurs fichiers CSV décrivant notamment :

- Les machines et leurs caractéristiques ;
- L'historique des réparations ;
- Les appels et événements de panne ;
- Les opérations de maintenance ;
- La maintenance préventive ;
- Les types de pannes et problèmes rencontrés ;
- Les actions de maintenance ;
- Les sites, catégories et emplacements des machines ;
- Certains historiques liés aux machines.

Deux documents complémentaires seront fournis :

Documentation détaillée des fichiers : Elle présente individuellement les principaux fichiers, leurs colonnes, leurs types, leur rôle et les principales relations observées.

Documentation globale du dataset : Elle présente le dataset comme un ensemble relationnel, son organisation générale ainsi que les principales relations entre les tables.

Ces documents constituent un support de compréhension. Ils ne remplacent pas l'exploration des données.

La documentation a été reconstruite à partir des exports disponibles de l'ERP. Certaines variables peuvent donc conserver une signification métier partiellement incertaine. Dans ce cas, vous devrez expliciter les hypothèses adoptées.

Règles importantes :

→ Le projet devra être réalisé **exclusivement à partir des données et de la documentation fournies**.

→ L'ajout d'un dataset externe ou l'enrichissement des observations à partir de sources externes n'est pas autorisé.

4. Organisation générale du projet

Le projet est divisé en trois parties successives :

Partie 1 : Data Preparation & Feature Engineering
Partie 2 : Supervised Learning
Partie 3 : Unsupervised Learning

La première partie est commune à tous les groupes. Pour les parties 2 et 3, chaque groupe choisira une problématique parmi celles proposées dans le présent cahier des charges.

Toute autre problématique devra obligatoirement être **validée préalablement par l'enseignante**.

PARTIE 1 : DATA PREPARATION & FEATURE ENGINEERING

Cette première partie consiste à transformer les données opérationnelles fournies par l'ERP en données propres, cohérentes, compréhensibles et exploitables pour l'analyse.

Il ne s'agit pas simplement d'appliquer quelques commandes Pandas.

Vous devez vous comporter comme un Data Analyst recevant pour la première fois des données provenant d'un système métier réel.

La question centrale de cette partie est :

Dans quel état avons-nous reçu les données et comment les avons-nous transformées pour qu'elles deviennent exploitables ?

1. Étape 1 : Compréhension et exploration des données

Vous devrez commencer par comprendre les données mises à votre disposition.

Il faudra notamment étudier :

- La taille de chaque fichier ;
- Les colonnes disponibles ;
- Les types des variables ;
- Les identifiants présents ;
- Les clés permettant de relier les fichiers ;
- La granularité des différentes tables ;
- Les périodes temporelles couvertes ;
- Les variables quantitatives et catégorielles ;
- Les valeurs manquantes ;
- Les doublons ;
- Les distributions principales ;
- Les valeurs aberrantes ou incohérentes ;
- Les variables quasiment constantes ;
- Les éventuelles redondances entre variables ou entre fichiers.

Des visualisations devront être utilisées lorsque celles-ci permettent de mieux comprendre les données.

Il est notamment attendu que vous soyez capables d'expliquer **ce que représente une ligne dans chacune des principales tables exploitées**.

2. Étape 2 : Évaluation de la qualité des données

Vous devrez réaliser un véritable audit de qualité des données. Les problèmes identifiés devront être quantifiés lorsque cela est possible.

Exemples :

- Pourcentage de valeurs manquantes ;

- Nombre de doublons ;
- Variables totalement ou presque totalement vides ;
- Dates impossibles ou incohérentes ;
- Durées négatives ;
- Modalités catégorielles incohérentes ;
- Identifiants sans correspondance dans une autre table ;
- Observations situées en dehors de la période étudiée.

Il ne suffit pas d'identifier un problème. Vous devez également expliquer : **Quelle décision avez-vous prise et pourquoi ?**

3. Étape 3 : Nettoyage et préparation

Les opérations réalisées dépendront des problèmes réellement observés.

Elles pourront notamment concerner :

- Traitement des valeurs manquantes ;
- Suppression ou conservation justifiée de certaines observations ;
- Suppression des doublons ;
- Conversion des types ;
- Traitement des dates ;
- Harmonisation des catégories ;
- Traitement raisonné des valeurs aberrantes ;
- Suppression de colonnes sans information utile ;
- Gestion des identifiants ;
- Préparation des variables catégorielles et quantitatives.

Chaque transformation importante devra être **justifiée**.

Une colonne ne doit pas être supprimée simplement parce qu'elle contient des valeurs manquantes, ni une valeur aberrante simplement parce qu'elle est différente des autres.

4. Étape 4 : Intégration des données

Le dataset étant composé de plusieurs fichiers, certaines analyses nécessiteront des **jointures.**

Vous devrez identifier :

- Quelles tables doivent être reliées ;
- Quelles clés utiliser ;
- Le type de jointure approprié ;
- La granularité de chaque table avant la jointure ;
- Les conséquences de la jointure sur le nombre d'observations.

Une attention particulière devra être portée aux relations **1–N**.

Une jointure mal réalisée peut dupliquer artificiellement des observations et modifier complètement les distributions ou les résultats du modèle.

Après chaque jointure importante, des vérifications devront donc être réalisées.

5. Étape 5 : Feature Engineering

À partir des variables originales, vous devrez construire des variables permettant de mieux représenter les phénomènes étudiés.

Selon la problématique et les données, les features pourront notamment concerner :

- L'âge d'une machine ;
- Le nombre de réparations précédentes ;
- Le nombre d'interventions sur une période donnée ;
- Le temps écoulé depuis la dernière réparation ;
- Le temps écoulé depuis le dernier entretien ;
- La fréquence des pannes ;
- La durée moyenne des réparations ;
- La durée cumulée des arrêts ;
- Le nombre de problèmes différents rencontrés ;
- Les tendances récentes ;
- Les historiques de maintenance ;
- Des ratios ;
- Des agrégations ;
- Des interactions entre variables ;
- Des informations temporelles ;
- Des catégories regroupées.

Chaque feature construite devra être documentée en indiquant :

nom de la feature → variables sources → méthode de calcul → signification → justification.

L'objectif n'est pas de créer le plus grand nombre possible de variables.

Une feature doit être créée parce qu'elle représente une information potentiellement utile pour la problématique étudiée.

6. Attention au Data Leakage

Le **Data Leakage** constituera un point important de l'évaluation.

Une information ne peut être utilisée pour réaliser une prédiction que si elle aurait réellement été disponible **au moment où cette prédiction aurait dû être réalisée**.

Cette règle est particulièrement importante pour les données temporelles.

Par exemple, pour prédire à une date ***T*** si une machine tombera prochainement en panne :

Les événements antérieurs à T peuvent être utilisés ; les informations produites après T ne peuvent pas être utilisées comme features.

Un modèle présentant des performances exceptionnellement élevées doit donc être examiné avec attention.

Une accuracy de 99 % n'est ni demandée ni nécessairement synonyme d'un bon modèle.

Une performance très élevée peut parfois révéler :

- Une fuite de données ;
- Une variable directement liée à la cible ;
- Un mauvais découpage train/test ;
- Un fort déséquilibre des classes ;
- Une erreur dans la construction du dataset.

7. Livrable de la Partie 1 : Rapport Data Preparation

Le premier rapport devra ressembler à un véritable **rapport d'analyse de données**. Il devra permettre à une personne n'ayant pas participé au projet de comprendre :

Comment les données ont été reçues, quels problèmes ont été trouvés, quelles décisions ont été prises et à quoi ressemble le dataset après transformation.

Le rapport devra notamment présenter :

1. Les sources de données exploitées ;
2. Leur structure et leurs relations ;
3. Les principales caractéristiques du dataset initial ;
4. L'analyse de la qualité des données ;
5. Les problèmes détectés ;
6. Les décisions de nettoyage adoptées ;
7. Les jointures réalisées ;
8. Les transformations effectuées ;
9. Les features construites ;
10. Les variables supprimées et leur justification ;
11. Une comparaison **avant / après préparation** ;
12. La description du ou des datasets analytiques obtenus ;
13. Les limites connues des données ;
14. Les risques éventuels de Data Leakage identifiés.

Les résultats importants devront être illustrés par des tableaux et des visualisations appropriées.

PARTIE 2 : SUPERVISED LEARNING

Chaque groupe devra choisir **une problématique supervisée parmi les trois propositions suivantes**.

Le dataset analytique préparé dans la Partie 1 pourra être repris, modifié ou enrichi afin de répondre à la problématique choisie.

Il est donc tout à fait acceptable de revenir sur la préparation des données après avoir défini précisément la cible.

En pratique : **Le Feature Engineering dépend de la question que l'on cherche à résoudre.**

1. Sujet S1 : Prédiction d'une panne future

Problématique

À partir de l'historique disponible jusqu'à une date donnée, peut:on prédire si une machine connaîtra une panne ou une réparation dans une période future définie ?

Exemple :
La machine aura-t-elle au moins une réparation dans les 30 prochains jours ?

Il faudra construire la variable cible à partir de l'historique temporel.

Les features devront exclusivement provenir d'informations disponibles **avant la date de prédiction**.

Cette problématique permet notamment d'exploiter :

- Historique des réparations ;
- Fréquence des pannes ;
- Historique d'entretien ;
- Age et caractéristiques de la machine ;
- Temps depuis la dernière panne ;
- Temps depuis la dernière opération de maintenance ;
- Evolutions récentes de l'activité de maintenance.

2. Sujet S2 : Prédiction du nombre de réparations futures

Problématique : Peut-on estimer le nombre de réparations qu'une machine connaîtra durant une période future ?

Exemple :
Combien de réparations la machine connaîtra-t-elle durant les 90 prochains jours?

Il s'agit d'un problème de prédiction quantitative.

Une attention particulière devra être portée :

- à la construction temporelle de la cible ;
- aux machines ayant très peu ou beaucoup de réparations ;
- à la distribution de la variable cible ;
- à l'interprétation des erreurs obtenues.

3. Sujet S3 : Prédiction de la durée ou de la gravité d'une réparation

Problématique : À partir des informations disponibles au début d'une intervention, peut-on estimer la durée de la réparation ou identifier les réparations susceptibles de provoquer un arrêt important ?

Deux variantes sont possibles :

→ **Régression :** prédire la durée de réparation ou d'arrêt.
→ **Classification :** prédire si l'intervention appartiendra à une catégorie telle que : arrêt court / arrêt important.

Le seuil retenu pour définir un arrêt important devra être **justifié à partir des données**.

Cette problématique nécessite une vigilance particulière : certaines informations présentes dans la table de réparation ne sont disponibles qu'après la fin de l'intervention et constitueraient donc du **Data Leakage** si elles étaient utilisées comme features.

4. Démarche attendue en Supervised Learning

Pour la problématique sélectionnée, vous devrez notamment :

- Définir précisément la cible ;
- Définir ce que représente une observation ;
- Déterminer quelles informations sont disponibles au moment de la prédiction ;
- Construire le dataset correspondant ;
- Effectuer un découpage approprié des données ;
- Définir une baseline ;
- Sélectionner un ou plusieurs modèles adaptés ;
- Entraîner les modèles ;
- Choisir des métriques adaptées à la problématique ;
- Analyser les erreurs ;
- Comparer les résultats ;
- Interpréter le comportement du modèle ;
- Identifier ses limites.

Pour une problématique temporelle, un découpage chronologique devra être privilégié lorsqu'il correspond au scénario réel d'utilisation.

Pour une classification déséquilibrée, l'accuracy seule sera insuffisante. Les métriques devront être choisies en fonction du problème.

5. Performance attendue

Aucun seuil minimal d'accuracy, de R^2 ou de toute autre métrique n'est imposé.

Vous ne serez pas évalués uniquement sur la performance numérique obtenue.

Un modèle de performance moyenne mais correctement construit et analysé peut être beaucoup plus intéressant qu'un modèle affichant 99 % d'accuracy sans justification.

L'évaluation portera notamment sur votre capacité à :

- Suivre correctement le processus Machine Learning ;
- Eviter le Data Leakage ;
- Sélectionner les bonnes données ;
- Choisir des métriques pertinentes ;
- Analyser les résultats ;
- Comprendre pourquoi le modèle fonctionne ou ne fonctionne pas ;
- Identifier les limites de votre approche.

PARTIE 3 : UNSUPERVISED LEARNING

Dans cette troisième partie, chaque groupe devra choisir **une problématique d'apprentissage non supervisé parmi les trois propositions ci-dessous**.

Contrairement à la partie supervisée, aucune variable cible n'est fournie au modèle. L'objectif consiste donc à découvrir une structure, des profils ou des comportements particuliers directement à partir des données.

Cette partie nécessite un travail important de **Feature Engineering**, car les résultats obtenus dépendront fortement de la manière dont les machines ou les événements sont représentés.

Le dataset préparé dans la Partie 1 pourra être repris, modifié ou enrichi en fonction de la problématique choisie.

Comme pour la partie supervisée, il est tout à fait acceptable de revenir sur certaines étapes de préparation lorsque cela est nécessaire.

1. Sujet U1 : Segmentation des machines selon leur profil de fiabilité

Problématique

Peut-on identifier différents profils de machines à partir de leur historique de fonctionnement, de réparation et de maintenance ?

L'objectif consiste à représenter chaque machine par un ensemble de caractéristiques décrivant son comportement dans le temps.

Les étudiants pourront, par exemple, construire des variables telles que :

- Nombre total de réparations ;
- Fréquence moyenne des réparations ;
- Nombre de réparations récentes ;
- Durée moyenne des réparations ;
- Durée cumulée des arrêts ;
- Nombre de problèmes différents rencontrés ;
- Temps écoulé depuis la dernière réparation ;
- Age de la machine ;
- Nombre d'opérations de maintenance ;
- Fréquence des entretiens.

Une méthode de clustering pourra ensuite être appliquée afin d'identifier des groupes de machines présentant des comportements similaires.

Travail attendu

Les groupes obtenus devront ensuite être **caractérisés et interprétés**.

Par exemple, l'analyse pourrait révéler des profils tels que :

- Machines relativement fiables ;
- Machines fréquemment en panne ;
- Machines connaissant peu de pannes mais des arrêts longs ;
- Machines nécessitant beaucoup d'entretien ;
- Machines présentant une forte diversité de problèmes.

Ces profils ne doivent cependant **pas être imposés à l'avance**. Ils devront être déduits des résultats réellement obtenus.

2. Sujet U2 : Segmentation des machines selon leur profil de maintenance

Problématique

Peut-on identifier différents comportements de maintenance parmi les machines du parc?

L'objectif est ici de représenter les machines à partir de leur historique de maintenance préventive et corrective.

Les features construites pourront notamment concerner :

- Nombre total d'entretiens ;
- Fréquence des opérations de maintenance ;
- Régularité des entretiens ;
- Temps écoulé depuis le dernier entretien ;
- Délai moyen entre deux entretiens ;
- Nombre de réparations correctives ;
- Rapport entre maintenance préventive et corrective ;
- Durée moyenne des opérations de maintenance ;
- Nombre d'actions de maintenance différentes.

L'objectif sera ensuite d'identifier des groupes cohérents et de comprendre ce qui distingue leurs comportements.

Exemple d'interprétation possible

L'analyse pourrait faire apparaître des machines :

- Régulièrement entretenues ;
- Peu entretenues ;
- Principalement entretenues après une panne ;
- Nécessitant des interventions fréquentes ;
- Présentant un déséquilibre important entre maintenance préventive et corrective.

Là encore, ces catégories ne doivent pas être définies avant l'analyse.

3. Sujet U3 : Détection de machines atypiques

Problématique

Peut-on identifier des machines dont le comportement de réparation ou de maintenance est inhabituel par rapport au reste du parc ?

L'objectif n'est plus nécessairement de construire des groupes, mais d'identifier des observations rares ou atypiques.

Une machine pourra, par exemple, être considérée comme atypique si elle présente :

- Une fréquence de panne inhabituellement élevée ;
- Une durée d'arrêt très importante ;
- Une accumulation rapide de réparations ;
- Une combinaison rare de problèmes ;
- Une fréquence de maintenance très différente des autres machines ;
- Un rapport inhabituel entre entretien préventif et réparations ;
- Un comportement global éloigné des autres machines du même type.

Travail attendu

Il ne suffira pas d'obtenir une liste d'anomalies.

Chaque groupe devra analyser les machines détectées et répondre à la question :

Pourquoi cette machine est-elle considérée comme atypique ?

Les résultats devront être expliqués à partir des features utilisées.

4. Démarche attendue en Unsupervised Learning

Pour la problématique choisie, le travail devra notamment comprendre :

- Définition précise de l'unité d'analyse ;
- Sélection des données utiles ;
- Création du dataset analytique ;
- Choix et justification des features ;
- Traitement des valeurs manquantes ;
- Traitement des variables catégorielles si nécessaire ;
- Mise à l'échelle des variables lorsque la méthode utilisée le nécessite ;
- Analyse de la distribution des features ;
- Identification d'éventuelles variables très redondantes ;
- Choix d'une ou plusieurs méthodes adaptées ;
- Choix et justification des paramètres ;
- Comparaison de plusieurs configurations lorsque cela est pertinent ;
- Visualisation des résultats ;
- Interprétation des groupes ou anomalies détectés ;
- Analyse critique des résultats.

Dans le cas d'un clustering, le choix du nombre de groupes devra être **justifié**, et non fixé arbitrairement.

Des métriques internes telles que le **Silhouette Score** pourront être utilisées lorsqu'elles sont adaptées, mais elles ne doivent pas remplacer l'interprétation métier des résultats.

Un clustering n'est pas considéré comme intéressant uniquement parce qu'il possède un bon score mathématique.

Les groupes obtenus doivent également être **compréhéhensibles et interprétables**.

5. Feature Engineering et apprentissage non supervisé

Le Feature Engineering occupe une place particulièrement importante dans cette partie.

Les fichiers ERP contiennent principalement des **événements** : réparations, entretiens, déplacements, etc.

Or, les algorithmes de clustering ou de détection d'anomalies nécessitent généralement une représentation sous forme de variables numériques ou catégorielles décrivant chaque observation.

Les étudiants devront donc transformer les historiques en features synthétiques.

Par exemple :

Machine
↓
Historique de réparations
↓
NbRepairs
MeanRepairDuration
TotalDowntime
DaysSinceLastRepair
NbDifferentProblems
...

Le choix de ces variables influence directement la structure découverte par l'algorithme.

Les étudiants devront donc être capables de justifier :

Pourquoi ces variables permettent-elles de représenter correctement le comportement étudié ?

6. Analyse des résultats

Une attention importante sera accordée à l'interprétation.

Pour chaque groupe ou comportement détecté, il faudra notamment examiner :

- Les valeurs moyennes ou médianes des principales features ;
- Les variables qui différencient le plus les groupes ;
- La taille des groupes ;
- Les éventuelles machines extrêmes ;
- Les caractéristiques communes aux machines appartenant au même groupe.

Des visualisations devront être utilisées pour faciliter cette analyse.

Une réduction de dimension telle que PCA pourra éventuellement être utilisée pour la visualisation, mais elle ne devra pas être utilisée uniquement pour produire un graphique esthétique.

Son utilisation devra avoir un objectif clairement expliqué.

7. Limites de l'approche

Les étudiants devront également discuter les limites de leurs résultats.

Par exemple :

- Choix des features ;
- Données manquantes ;
- Qualité des historiques disponibles ;
- Choix de la période étudiée ;
- Déséquilibre entre certains types de machines ;
- Sensibilité aux paramètres des algorithmes ;
- Difficulté d'interprétation de certains clusters ;
- Absence de vérité terrain permettant de confirmer les groupes obtenus.

Un résultat non supervisé doit être considéré comme une **structure découverte dans les données**, et non comme une vérité métier automatiquement établie.

À PROPOS DU RENDU

1. Problématiques alternatives

Les problématiques proposées constituent le cadre principal du projet. Un groupe peut toutefois proposer :

- Une autre problématique supervisée ;
- Une autre problématique non supervisée ;
- Une variante significative d'une problématique proposée.

Cependant, **toute problématique différente doit obligatoirement être validée par l'enseignante avant son développement.**

Cette validation permettra de vérifier que :

- La problématique est réalisable avec les données disponibles ;
- Elle correspond aux objectifs pédagogiques du module ;
- Elle nécessite un véritable travail de préparation et de feature engineering ;
- Elle présente une difficulté suffisante ;
- Elle ne repose pas sur une fuite de données ;
- Elle peut être correctement évaluée.

2. Organisation générale des rendus

Le projet est évalué en **trois étapes successives**.

Rendu	Partie	Éléments à remettre
Rendu 1	Data Preparation & Feature Engineering	Rapport + Code + Soutenance technique
Rendu 2	Supervised Learning	Rapport + Code + Soutenance technique
Rendu 3	Unsupervised Learning	Rapport + Code + Soutenance technique

Chaque étape constitue un travail complet et sera évaluée séparément.

3. Rapport

Pour chacune des trois parties, un rapport devra être remis.

Le rapport doit permettre de comprendre :

Ce qui a été réalisé, pourquoi cela a été réalisé, quels résultats ont été obtenus et comment ces résultats sont interprétés.

Le rapport ne doit pas être :

- Une succession de captures d'écran ;
- Une copie du notebook ;
- Une liste de fonctions python ;
- Une présentation sans analyse.

Il doit présenter une **démarche structurée et argumentée**.

Les résultats importants devront être accompagnés de tableaux ou de visualisations lorsque cela facilite leur compréhension.

4. Code

Le code devra être fourni avec chaque rendu.

Il devra être :

- Organisé ;
- Lisible ;
- Reproductible ;
- Exécutable dans un ordre logique ;
- Suffisamment commenté ;
- Cohérent avec les résultats présentés dans le rapport.

Les différentes étapes doivent pouvoir être identifiées clairement :

→ Chargement
→ Exploration
→ Préparation
→ Feature Engineering
→ Modélisation
→ Évaluation
→ Analyse

Une attention particulière sera portée à la capacité à reproduire les résultats présentés.

5. Soutenance technique

Chaque partie donnera lieu à une **soutenance technique**.

L'objectif n'est pas uniquement de présenter des slides.

Les étudiants devront être capables de défendre les choix réalisés.

Des questions pourront notamment porter sur :

- La structure des données ;
- Les relations entre fichiers ;
- Les choix de nettoyage ;
- Les jointures ;
- Les features construites ;
- Les variables supprimées ;
- Les méthodes de machine learning choisies ;
- Les paramètres utilisés ;
- Les métriques ;
- Les risques de data leakage ;
- Les résultats ;
- Les erreurs rencontrées ;
- Les limites de la solution ;
- Certaines parties du code.

Chaque membre du groupe doit donc comprendre l'ensemble de la démarche.

6. Critère fondamental d'évaluation

Ce projet constitue avant tout une évaluation de la **maîtrise du processus Data & Machine Learning**.

L'objectif n'est pas de rechercher uniquement la meilleure performance numérique.

La démarche suivante sera particulièrement valorisée :

Comprendre → Préparer → Construire → Justifier → Modéliser → Évaluer → Interpréter → Critiquer

Une solution obtenant une performance moyenne mais présentant une méthodologie rigoureuse et une analyse pertinente pourra être mieux évaluée qu'une solution présentant une performance très élevée sans compréhension du processus.

Les difficultés, échecs et limites ne doivent donc pas être dissimulés.

Ils doivent être :

- Identifiés ;
- Expliqués ;
- Analysés.

Performance des modèles

Aucun seuil minimal de performance n'est imposé.

Vous n'êtes donc pas obligés d'obtenir :

- 99 % d'accuracy ;
- Un R^2 très élevé ;
- Un Silhouette Score exceptionnel.

Une performance très élevée peut même parfois révéler un problème méthodologique.

L'objectif est de démontrer que vous êtes capables de :

- Construire correctement le problème ;
- Utiliser les données disponibles de manière pertinente ;
- Eviter le data leakage ;
- Choisir les méthodes appropriées ;
- Evaluer correctement les résultats ;
- Comprendre les limites du modèle ou de l'analyse.

7. Dataset autorisé

Le projet devra être réalisé **exclusivement à partir du dataset ERP Maintenance fourni avec le sujet**.

Les fichiers de documentation fournis font partie intégrante du projet.

L'utilisation de datasets externes pour remplacer ou enrichir les observations n'est pas autorisée.

Les fichiers facultatifs fournis en annexe peuvent être utilisés pour enrichir une analyse, mais leur utilisation n'est pas obligatoire.

L'objectif n'est pas d'utiliser le maximum de fichiers possible, mais de sélectionner les données réellement pertinentes pour la problématique étudiée.

8. Importance du projet dans l'évaluation du module

Ce projet constitue l'**évaluation principale du module**. **La note finale obtenue pour ce projet correspondra à la note de l'examen principal.**

Les trois parties permettront d'évaluer progressivement :

- Partie 1 : capacité à comprendre, préparer et transformer des données réelles.
- Partie 2 : capacité à construire et évaluer une solution de Machine Learning supervisé.
- Partie 3 : capacité à explorer des données sans cible et à interpréter des structures ou comportements découverts.

L'évaluation portera donc autant sur la **méthodologie**, la **compréhension** et l'**analyse** que sur les résultats numériques obtenus.

Bon travail